



Đại học Quốc gia Thành phố Hồ Chí Minh
Trường Đại học Công nghệ Thông tin

CS231.P21.KHTN - THỊ GIÁC MÁY TÍNH

Animals Classification

Sinh Viên :


Nguyễn Văn Minh - 23520945

Phan Nhật Tân - 23521405

Giảng viên :

TS. Mai Tiến Dũng

Ngày 23 tháng 6 năm 2025



Mục lục

1	GIỚI THIỆU CHUNG	2
1.1	THÀNH VIÊN VÀ SỰ ĐÓNG GÓP	2
1.2	LÝ DO CHỌN ĐỀ TÀI	3
2	NỘI DUNG CHÍNH	4
2.1	PHÁT BIỂU BÀI TOÁN	4
2.2	PHƯƠNG PHÁP GIẢI QUYẾT	5
2.2.1	Tổng quan phương pháp finetuning model EfficientnetB3	5
2.2.2	Phân tích mô hình EfficientNetB3	5
2.2.3	Tăng cường dữ liệu (Data Augmentation)	5
2.2.4	Tinh chỉnh mô hình (Fine-tuning EfficientNetB3)	6
2.2.5	Huấn luyện mô hình	6
2.2.6	Tổng quan phương pháp finetuning model InceptionV3	7
2.2.7	Phương pháp HOG kết hợp với mô hình học máy truyền thống . . .	8
2.3	KẾT QUẢ THỰC NGHIỆM	9
2.3.1	Tập dữ liệu sử dụng	9
2.3.2	Hàm loss huấn luyện	9
2.3.3	Đánh giá kết quả mô hình	10
2.3.4	Nhận xét	11
2.4	ĐÁNH GIÁ NHỮNG ƯU ĐIỂM VÀ HẠN CHẾ	11
2.4.1	Ưu điểm	11
2.4.2	Hạn chế	12
2.5	Source code	12

Chương 1

GIỚI THIỆU CHUNG

1.1 THÀNH VIÊN VÀ SỰ ĐÓNG GÓP

Với đề án này nhóm tụi em đã có sự phân công công việc ngang bằng nhau mỗi bạn đảm nhiệm những nhiệm vụ nhất định và có thống nhất với nhau từ trước nên mọi sự việc đều diễn ra suôn sẻ và thể hiện được rõ tinh thần đóng góp cầu tiến của mình. Bảng phân công được thể hiện ở dưới đây:

Tên	Công việc
Nguyễn Văn Minh	• Phụ trách mô hình EfficientNetB3: tải mô hình, fine-tune, huấn luyện và đánh giá. • Viết phần báo cáo và soạn slide liên quan đến mô hình EfficientNetB3.
Phan Nhật Tân	• Phụ trách mô hình InceptionV3 : tải mô hình, fine-tune, huấn luyện và đánh giá. • Viết phần báo cáo và soạn slide liên quan đến mô hình InceptionV3 .

Cả hai thành viên cùng phối hợp thực hiện:

- Tiền xử lý dữ liệu, tổ chức thư mục dự án.
- So sánh hiệu năng mô hình (độ chính xác, tốc độ, kích thước, overfitting...).
- Viết phần mở đầu, kết luận, và phần đánh giá tổng quan.
- Tham gia tổng hợp kết quả và so sánh các mô hình.
- Thiết kế slide và trình bày phần tổng quan mô hình.



1.2 LÝ DO CHỌN ĐỀ TÀI

Trong bối cảnh công nghệ trí tuệ nhân tạo ngày càng phát triển, các hệ thống nhận dạng và phân loại hình ảnh đang đóng vai trò quan trọng trong nhiều lĩnh vực thực tiễn. Một trong những ứng dụng nổi bật là hệ thống phân loại động vật dựa trên hình ảnh, có tiềm năng ứng dụng rộng rãi trong đời sống và nghiên cứu khoa học.

Cụ thể, hệ thống phân loại động vật có thể được tích hợp trong:

- **Các nền tảng hỗ trợ du lịch/sở thú:** Giúp khách tham quan dễ dàng tra cứu thông tin về các loài động vật bằng cách chụp ảnh hoặc quét mã, từ đó nâng cao trải nghiệm và mức độ tương tác.
- **Hệ thống giám sát bảo tồn:** Tự động nhận diện và theo dõi các loài động vật qua camera tại rừng quốc gia hoặc khu bảo tồn, đặc biệt hữu ích trong việc giám sát các loài quý hiếm hoặc có nguy cơ tuyệt chủng.
- **Ứng dụng trong giáo dục và nghiên cứu:** Hỗ trợ học sinh, sinh viên và nhà nghiên cứu nhận diện nhanh chóng và chính xác các loài phục vụ công tác học tập, khảo sát sinh học hoặc lập bản đồ phân bố sinh vật.

Tuy nhiên, bài toán phân loại nhiều loài động vật là một thách thức không nhỏ do tính chất phức tạp của dữ liệu. Nhiều loài có hình dạng, màu sắc, hoặc kích thước tương đồng nhau khiến việc phân biệt bằng mắt thường (và cả bằng mô hình học máy thông thường) trở nên khó khăn. Do đó, việc xây dựng một mô hình học sâu có khả năng trích xuất đặc trưng tốt và phân loại chính xác là điều cần thiết.

Ngoài ra, đề tài này còn có ý nghĩa về mặt học thuật khi kết hợp giữa xử lý ảnh và mạng neural, đồng thời tạo tiền đề cho các hướng nghiên cứu mở rộng trong tương lai như phân loại động vật trong môi trường tự nhiên, nhận dạng hành vi động vật, hoặc tích hợp với các hệ thống phân tích video thời gian thực.

Vì những lý do trên, nhóm em chọn đề tài “Xây dựng hệ thống phân loại động vật qua hình ảnh” nhằm giải quyết một bài toán vừa mang tính thực tiễn, vừa có giá trị nghiên cứu cao.

Chương 2

NỘI DUNG CHÍNH

2.1 PHÁT BIỂU BÀI TOÁN

Tên đề án: *Animals Classification*

Input: Một ảnh số chứa một cá thể động vật cần phân loại, cùng với một tập dữ liệu huấn luyện gồm các ảnh động vật đã được gán nhãn chính xác theo từng loài.

Output: Nhãn (tên loài) tương ứng với ảnh động vật được đưa vào hệ thống.

Mô tả bài toán: Bài toán phân loại động vật là một bài toán thuộc nhóm *image classification* trong lĩnh vực thị giác máy tính (*computer vision*). Mục tiêu là phát triển một mô hình học sâu (deep learning) có khả năng tự động nhận diện và phân loại hình ảnh động vật đầu vào thành một trong các lớp (loài) đã biết.

Hệ thống phải đảm bảo hai tiêu chí chính:

- **Độ chính xác cao:** Phân biệt được các loài có ngoại hình tương đồng như báo hoa và báo đốm, mèo rừng và mèo nhà,...
- **Khả năng tổng quát hóa tốt:** Dự đoán chính xác trên các ảnh mới (chưa từng thấy trong quá trình huấn luyện), bao gồm ảnh có góc chụp, ánh sáng, và hậu cảnh khác nhau.

Bài toán cũng có thể được mở rộng sang bài toán phân lớp đa cấp (hierarchical classification) nếu phân loại theo họ, chi, loài, hoặc tích hợp thêm các mô-đun phát hiện đối tượng (object detection) nếu ảnh chứa nhiều loài cùng lúc.

Việc giải quyết hiệu quả bài toán này không chỉ có ý nghĩa về mặt kỹ thuật mà còn đóng góp cho các lĩnh vực như bảo tồn sinh vật, giáo dục sinh học, và các ứng dụng phổ thông như app du lịch, nhận dạng ảnh trong đời sống.



2.2 PHƯƠNG PHÁP GIẢI QUYẾT

2.2.1 Tổng quan phương pháp finetuning model EfficientnetB3

Để giải quyết bài toán phân loại động vật, nhóm sử dụng phương pháp học sâu dựa trên mô hình tiền huấn luyện (*pre-trained model*), cụ thể là kiến trúc EfficientNetB3. Kết hợp với đó là kỹ thuật *fine-tuning* nhằm tối ưu hóa hiệu năng trên tập dữ liệu cụ thể. Đồng thời, nhóm áp dụng kỹ thuật *data augmentation* để mở rộng và đa dạng hóa dữ liệu đầu vào, giúp giảm hiện tượng overfitting và cải thiện khả năng tổng quát của mô hình.

2.2.2 Phân tích mô hình EfficientNetB3

EfficientNet là một dòng kiến trúc mạng nơ-ron tích chập (CNN) hiện đại do Google AI đề xuất, nổi bật với hiệu năng cao và số lượng tham số tương đối nhỏ. Điểm khác biệt chính của EfficientNet là chiến lược *compound scaling* — đồng thời mở rộng chiều sâu (depth), chiều rộng (width) và độ phân giải ảnh (resolution) theo một tỷ lệ tối ưu hóa.

EfficientNetB3 là một trong các biến thể của dòng mô hình này, đạt hiệu suất tốt hơn so với các kiến trúc truyền thống như ResNet hoặc Inception với cùng số lượng tham số. Cụ thể, EfficientNetB3 có:

- Khoảng 12 triệu tham số (so với hơn 20 triệu ở ResNet50).
- Khả năng trích xuất đặc trưng mạnh mẽ từ ảnh kích thước đầu vào $224 \times 224 \times 3$.
- Được huấn luyện sẵn trên tập ImageNet, do đó có khả năng nhận diện đặc trưng hình ảnh tốt ngay từ đầu.

Việc sử dụng mô hình này giúp giảm thời gian huấn luyện, tận dụng tri thức từ tập dữ liệu lớn, đồng thời vẫn đạt độ chính xác cao khi được tinh chỉnh đúng cách.

2.2.3 Tăng cường dữ liệu (Data Augmentation)

Trước khi huấn luyện mô hình, dữ liệu được xử lý bằng kỹ thuật tăng cường nhằm cải thiện tính đa dạng và khả năng tổng quát hóa. Cụ thể, nhóm sử dụng các phép biến đổi sau:

- Xoay ảnh ngẫu nhiên trong phạm vi $\pm 20^\circ$.
- Dịch ảnh theo chiều ngang và dọc trong phạm vi 20%.
- Áp dụng biến dạng shear và zoom ngẫu nhiên.
- Lật ngang ảnh.
- Sử dụng chế độ `fill_mode='nearest'` để nội suy các pixel trống sau biến đổi.

Mã nguồn Python áp dụng như sau:



```
1 datagen = ImageDataGenerator(  
2     rotation_range=20,  
3     width_shift_range=0.2,  
4     height_shift_range=0.2,  
5     shear_range=0.2,  
6     zoom_range=0.2,  
7     horizontal_flip=True,  
8     fill_mode='nearest'  
9 )
```

2.2.4 Tinh chỉnh mô hình (Fine-tuning EfficientNetB3)

Sau khi tải mô hình EfficientNetB3 với trọng số tiền huấn luyện từ ImageNet, nhóm thực hiện tinh chỉnh (fine-tune) một phần các tầng cuối nhằm thích ứng mô hình với tập dữ liệu mới:

- Đóng băng các tầng đầu (vì đặc trưng cơ bản thường giống nhau giữa các tập ảnh).
- Chỉ mở khóa (`trainable=True`) 50 tầng cuối của mô hình.

Mô hình được xây dựng theo cấu trúc sau:

```
1 model = Sequential([  
2     base_model,  
3     GlobalAveragePooling2D(),  
4     Dense(512, activation='relu'),  
5     Dropout(0.5),  
6     Dense(len(animal_names), activation='softmax')  
7 ])
```

2.2.5 Huấn luyện mô hình

Mô hình được huấn luyện với hàm mất mát `sparse_categorical_crossentropy` và bộ tối ưu hoá Adam với learning rate ban đầu là 10^{-4} . Nhằm tránh overfitting và cải thiện tốc độ hội tụ, nhóm sử dụng thêm bộ điều chỉnh learning rate tự động `ReduceLROnPlateau` theo dõi `val_loss`:

```
1 lr_scheduler = ReduceLROnPlateau(  
2     monitor='val_loss',  
3     factor=0.2,  
4     patience=5,  
5     min_lr=1e-6  
6 )
```

Quá trình huấn luyện sử dụng dữ liệu đã được tăng cường như sau:

```
1 history = model.fit(  
2     datagen.flow(X_train, y_train, batch_size=8),  
3     epochs=50,  
4     validation_data=(X_test, y_test),
```



```
5 callbacks=[lr_scheduler]  
6 )
```

Kết quả huấn luyện được ghi nhận và đánh giá bằng độ chính xác (accuracy) trên tập kiểm thử, từ đó tiếp tục được phân tích ở các phần sau.

2.2.6 Tổng quan phương pháp finetuning model InceptionV3

InceptionV3 là một kiến trúc mạng nơ-ron tích chập (CNN) sâu được thiết kế để tối ưu hiệu quả phân loại ảnh trên tập dữ liệu lớn như ImageNet. Đây là phiên bản cải tiến từ các mô hình Inception trước đó (GoogLeNet, InceptionV1/V2) với nhiều cải tiến về hiệu suất và độ sâu mạng. Mô hình sử dụng khối Inception để thay vì tăng chiều sâu đơn thuần, kết hợp nhiều kernel với kích thước khác nhau để trích xuất đặc trưng ở nhiều cấp độ.

- **Tiền huấn luyện:** Mô hình được huấn luyện trước trên ImageNet, giúp tận dụng tri thức học được từ tập ảnh lớn.
- **Đầu vào:** Ảnh kích thước $299 \times 299 \times 3$.
- **Tổng số tham số:** khoảng 23 triệu.

Cấu trúc mô hình được sử dụng

Trong đề án, nhóm sử dụng mô hình InceptionV3 từ `tensorflow.keras.applications` với các thay đổi sau:

- **Phần đầu (base model):** Giữ nguyên kiến trúc pretrained, đóng vai trò trích xuất đặc trưng.
- **Các tầng bổ sung:**
 - `GlobalAveragePooling2D()`: giảm chiều dữ liệu, tránh overfitting và giảm tham số.
 - `Dense(1000, activation='selu')`: tầng kết nối đầy đủ với hàm kích hoạt selu giúp ổn định gradient và học phi tuyến mạnh.
 - `Dropout(0.5)`: giảm overfitting bằng cách ngẫu nhiên bỏ bớt 50% neuron.
 - `Dense(num_classes, activation='softmax')`: tầng đầu ra với số node bằng số lớp cần phân loại.

Chiến lược huấn luyện

Việc huấn luyện mô hình được chia làm hai giai đoạn nhằm tối ưu hóa hiệu suất mô hình:

Giai đoạn 1: Huấn luyện phần đầu ra (head training)

- Đóng băng toàn bộ trọng số của mô hình pretrained.
- Chỉ huấn luyện các tầng mới thêm vào.
- Optimizer: Adam, learning rate = 1×10^{-3} .
- Số epoch: 10.



Giai đoạn 2: Fine-tuning mô hình

- Bỏ đóng băng 50 lớp cuối của mô hình InceptionV3.
- Huấn luyện toàn bộ mô hình (bao gồm cả backbone và head).
- Dùng `ReduceLROnPlateau` theo dõi `val_loss`, nếu không cải thiện sau 5 epoch thì giảm learning rate xuống còn 0.2 lần.
- Optimizer: Adam với learning rate nhỏ.
- Batch size = 32.
- Epoch tổng cộng (cả 2 giai đoạn): 40.

2.2.7 Phương pháp HOG kết hợp với mô hình học máy truyền thống

Bên cạnh các mô hình học sâu hiện đại, nhóm cũng thực hiện thử nghiệm một hướng tiếp cận truyền thống sử dụng đặc trưng **HOG (Histogram of Oriented Gradients)** kết hợp với các mô hình học máy cổ điển như **Linear SVM** và **Random Forest**.


Histogram of Oriented Gradients (HOG) là một kỹ thuật trích xuất đặc trưng hình ảnh, dựa trên sự phân bố hướng của gradient trong các vùng con nhỏ (cells) của ảnh. Phương pháp này đã được sử dụng rộng rãi trong các bài toán nhận dạng vật thể, đặc biệt là nhận diện người.

- Ảnh đầu vào được resize về kích thước cố định để chuẩn hoá quá trình trích xuất đặc trưng.
- Sử dụng thư viện `scikit-image` để tính toán đặc trưng HOG cho từng ảnh.
- Các đặc trưng HOG sau đó được sử dụng làm đầu vào cho mô hình học máy.

Nhóm thử nghiệm hai mô hình học máy phổ biến:

1. **Linear SVM (Support Vector Machine):** Mô hình phân loại tuyến tính, tối ưu biên phân tách giữa các lớp. Phù hợp với các bài toán có dữ liệu đặc trưng tuyến tính hoặc gần tuyến tính.
2. **Random Forest:** Mô hình tổ hợp gồm nhiều cây quyết định, giúp giảm overfitting và cải thiện tính tổng quát của mô hình.

Mặc dù đơn giản và dễ triển khai, các phương pháp này cho độ chính xác không cao trong bối cảnh phân loại động vật với nhiều lớp và đặc trưng phức tạp. Tuy nhiên, việc triển khai các mô hình này vẫn có ý nghĩa nhất định để làm cơ sở so sánh với các mô hình học sâu hiện đại.



Hình 2.1: Minh hoạ đặc trưng HOG trích xuất từ ảnh động vật

2.3 KẾT QUẢ THỰC NGHIỆM

2.3.1 Tập dữ liệu sử dụng

Trong quá trình thực nghiệm, nhóm sử dụng tập dữ liệu **Animal Image Dataset**, được thu thập từ Google Images. Tập dữ liệu bao gồm hình ảnh của **90 loài động vật khác nhau**, với mỗi loài có số lượng ảnh tương đối đồng đều.

Nguồn dữ liệu: [Animal Image Dataset trên Kaggle](#).

Lý do chọn tập dữ liệu này:

- **Độ đa dạng cao:** Bao gồm nhiều loài động vật thuộc các nhóm khác nhau (thú, chim, bò sát...), tạo điều kiện huấn luyện mô hình có tính tổng quát.
- **Thử thách thực tế:** Một số loài có hình dạng và màu sắc tương đồng (ví dụ: báo, mèo rừng, hổ...), đòi hỏi mô hình có khả năng phân biệt tốt các đặc trưng tinh vi.
- **Cân bằng lớp:** Dữ liệu không bị thiên lệch về số lượng ở bất kỳ lớp nào, giúp mô hình không bị bias trong quá trình huấn luyện.

Ảnh đầu vào được resize về kích thước 224×224 và chuẩn hoá để phù hợp với yêu cầu của mô hình EfficientNetB3 và các mô hình CNN khác.

2.3.2 Hàm loss huấn luyện

Trong quá trình huấn luyện mô hình phân loại ảnh động vật, hàm mất mát (*loss function*) được sử dụng là **sparse categorical crossentropy**. Đây là một biến thể của hàm cross-entropy truyền thống, phù hợp khi nhãn (*labels*) là các số nguyên đại diện cho lớp thay vì các vector one-hot.

Giả sử mô hình có C lớp đầu ra và đầu ra của mô hình là một vector xác suất $\hat{y} = (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_C)$ với $\hat{y}_i$ là xác suất dự đoán thuộc lớp i , và nhãn thực tế là một số nguyên $y \in \{0, 1, \dots, C - 1\}$ thì hàm mất mát được tính như sau:

$$\mathcal{L}(y, \hat{y}) = -\log(\hat{y}_y)$$



Trong đó:

- $\hat{y}_y$ là xác suất được mô hình dự đoán cho lớp đúng y .
- Hàm logarit giúp phạt nặng hơn những dự đoán sai có xác suất thấp.

Hàm mất mát này được tối thiểu hóa trong quá trình huấn luyện thông qua thuật toán tối ưu hóa Adam, nhằm giúp mô hình cải thiện độ chính xác phân loại trên tập dữ liệu động vật. Vì nhãn đầu vào là số nguyên, nên `sparse_categorical_crossentropy` là lựa chọn phù hợp và hiệu quả hơn so với `categorical_crossentropy` (yêu cầu nhãn dạng one-hot).

2.3.3 Đánh giá kết quả mô hình

Để đánh giá chất lượng mô hình, nhóm sử dụng độ đo **accuracy** trên tập kiểm thử. Các mô hình được huấn luyện và so sánh bao gồm cả mô hình học sâu (deep learning) và mô hình truyền thống (machine learning).

Kết quả so sánh giữa các mô hình học sâu:

Mô hình	Accuracy
InceptionV3 (huấn luyện 1 giai đoạn)	0.83
InceptionV3 (huấn luyện 2 giai đoạn)	0.89
EfficientNetB3 (fine-tuning)	0.95


Kết quả cho thấy mô hình EfficientNetB3 đạt độ chính xác cao nhất với 95%, vượt trội so với các kiến trúc CNN truyền thống. Việc áp dụng chiến lược fine-tuning kết hợp với data augmentation đã giúp mô hình học được đặc trưng phân biệt tốt hơn.

Kết quả so sánh với phương pháp truyền thống (HOG + ML):


Phương pháp	Accuracy
HOG + Linear SVM	0.27
HOG + Random Forest	0.28

Các phương pháp truyền thống sử dụng đặc trưng HOG kết hợp với các mô hình học máy cổ điển như SVM và Random Forest chỉ đạt độ chính xác khoảng 27–28%. Điều này khẳng định sự cần thiết của việc sử dụng các mô hình học sâu hiện đại trong các bài toán thị giác máy tính phức tạp như phân loại động vật.

Biểu đồ Accuracy và Loss khi huấn luyện các mô hình:




(a) Accuracy của EfficientNetB3




(b) Loss của EfficientNetB3

Hình 2.2: Biểu đồ huấn luyện của mô hình EfficientNetB3



(a) Accuracy của InceptionV3



(b) Loss của InceptionV3

Hình 2.3: Biểu đồ huấn luyện của mô hình InceptionV3

2.3.4 Nhận xét

- Mô hình học sâu, đặc biệt là EfficientNetB3, cho kết quả vượt trội so với các phương pháp cổ điển.
- Việc huấn luyện nhiều giai đoạn và sử dụng data augmentation đóng vai trò quan trọng trong việc nâng cao độ chính xác.
- Tập dữ liệu đa dạng và cân bằng là một trong những yếu tố then chốt giúp mô hình học hiệu quả và không bị bias.

Những kết quả này cho thấy mô hình có tiềm năng áp dụng trong các hệ thống phân loại động vật thực tế như ứng dụng học tập, giám sát động vật hoang dã, và hỗ trợ du lịch.

2.4 ĐÁNH GIÁ NHỮNG ƯU ĐIỂM VÀ HẠN CHẾ

2.4.1 Ưu điểm

- **Hiệu suất cao:** Mô hình EfficientNetB3 đạt accuracy lên đến **95%** trên tập kiểm thử, cho thấy khả năng học và phân biệt đặc trưng rất tốt giữa các loài động vật có hình thái tương đồng.



- **Khả năng tổng quát hóa tốt:** Nhờ áp dụng kỹ thuật *data augmentation* và *fine-tuning*, mô hình có khả năng dự đoán chính xác trên các ảnh chưa từng xuất hiện trong tập huấn luyện.
- **Tận dụng hiệu quả mô hình tiền huấn luyện:** Cả hai mô hình InceptionV3 và EfficientNetB3 đều được khởi tạo từ trọng số pretrained trên ImageNet, giúp rút ngắn thời gian huấn luyện và đạt kết quả cao ngay cả khi dữ liệu huấn luyện không quá lớn.
- **So sánh đa phương pháp:** Việc kết hợp thử nghiệm cả học sâu và học máy truyền thống giúp đánh giá toàn diện và khách quan hiệu quả của từng phương pháp.
- **Khả năng mở rộng:** Mô hình có thể dễ dàng mở rộng để áp dụng vào bài toán nhận dạng đa lớp hơn, phân cấp theo họ/chi/loài, hoặc tích hợp với các bài toán detection/video real-time trong tương lai.

2.4.2 Hạn chế

- **Yêu cầu tài nguyên phần cứng:** Mặc dù EfficientNetB3 có kích thước tương đối nhỏ so với các mô hình khác, việc fine-tune và huấn luyện trên GPU vẫn là điều cần thiết để đạt hiệu quả tốt. Trong môi trường không có GPU, thời gian huấn luyện có thể kéo dài và dễ gặp lỗi tràn RAM.
- **Dữ liệu chưa đảm bảo độ tự nhiên cao:** Tập dữ liệu thu thập từ Google Images có thể chứa các ảnh đã qua xử lý, ảnh minh họa hoặc không thực sự phản ánh điều kiện môi trường tự nhiên của động vật.

2.5 Source code

Source code có ở [Github](#).

Tài liệu tham khảo

- [1] Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2015). *Rethinking the Inception Architecture for Computer Vision*. arXiv preprint arXiv:1512.00567.
- [2] Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V., & Rabinovich, A. (2014). *Going Deeper with Convolutions*. arXiv preprint arXiv:1409.4842.
- [3] Tan, M., & Le, Q. V. (2019). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. arXiv preprint arXiv:1905.11946.
- [4] Tan, M., & Le, Q. V. (2021). *EfficientNetV2: Smaller Models and Faster Training*. In Proceedings of the 38th International Conference on Machine Learning (ICML), PMLR, arXiv:2104.00298.
- [5] Khan, A., Sohail, A., Zahoor, U., & Qureshi, A. S. (2021). *A Survey of the Recent Architectures of Deep Convolutional Neural Networks*. Artificial Intelligence Review, 53, pp. 5455–5516. (Phân tích các mô hình CNN hiện đại, trong đó có phân loại động vật.)
- [6] Horn, M., Einhäuser, W., & Ritschel, T. (2021). *The Animals-10 Dataset for Multi-class Animal Image Classification*. arXiv preprint arXiv:2105.13268. (Dataset phổ biến gồm 10 loài động vật, hỗ trợ huấn luyện Inception/EfficientNet.)